

UNIVERSIDAD DE GRANADA

Departamento de Ciencias de la Computación e Inteligencia Artificial

Inteligencia de Negocio

Guion de Prácticas

Práctica 1 – Clasificación

Curso 2026/27

Práctica 1

Clasificación

1.1. Objetivos y evaluación

Esta primera práctica introduce el uso de algoritmos de aprendizaje supervisado de clasificación para el análisis predictivo sobre conjuntos de datos. El objetivo es adquirir competencias para resolver problemas reales mediante minería de datos, transformándolos en conocimiento útil para la toma de decisiones. Se aplicarán diversos algoritmos sobre conjuntos de datos reales y se redactará un informe con los resultados obtenidos.

1.2. Conjuntos de datos

Trabajaremos con tres problemas cuyos conjuntos de datos están disponibles para su descarga en el espacio de PRADO de la asignatura. En concreto, abordaremos dos problemas de **clasificación binaria** y un problema de **clasificación multiclase**. Cada conjunto de datos deberá ser analizado para determinar diferentes aspectos, como balanceo de clases, distribución de valores, existencia de valores nulos, etc. Los problemas a abordar son los siguientes:

- ***Attrition prediction***. Este *dataset* contiene datos sobre los empleados de una empresa, incluyendo campos como su salario, departamento, años de experiencia o rol en la empresa. El objetivo es determinar si el usuario ha abandonado o no la organización en base a sus características. Se plantea un problema de clasificación binaria donde debemos predecir el valor de la variable `Attrition` (`Yes`/`No`). Un modelo de clasificación efectivo permitirá evitar el abandono e incentivar a determinados perfiles de empleados.

- ***E-commerce***. Un conjunto de datos que incluye información sobre pedidos en una empresa de comercio electrónico. Se recopilan datos como el medio de transporte del paquete, coste del producto o su peso. El objetivo es determinar (mediante un modelo de clasificación binaria) si el pedido llegará o no a tiempo al cliente, según indica la variable `Reached.on.Time_Y.N` (`Yes`/`No`).

- ***Tanzania***[1]. Un conjunto de datos sobre puntos de abastecimiento de agua en Tanzania. Se incluyen variables relacionadas con la ubicación, antigüedad, financiación, instalación, gestión, calidad y cantidad del agua, así como el tipo de bomba. El objetivo es determinar (mediante un modelo de clasificación multiclase sobre la variable `status_group`) si cada punto de agua está operativo (`functional`), requiere reparaciones (`functional needs`

[1] En este *dataset*, las características y las etiquetas se encuentran en ficheros diferentes. Será necesario unirlos de acuerdo al campo `id`.

`repair`) o no funciona (`non functional`), con el fin de mejorar las tareas de mantenimiento y garantizar el acceso a agua potable.

Importante

Aunque es posible descargar los conjuntos de datos desde las fuentes originales, se deberán utilizar **exclusivamente** las versiones de los *datasets* disponibles en PRADO.

1.3. Tareas a realizar

Sobre cada conjunto de datos se deberán resolver las siguientes tareas:

1. Para la resolución de cada problema se considerarán, al menos, **cinco algoritmos** de clasificación distintos. Se valorará la selección justificada de estos en función de las características del conjunto de datos de entrada. Algunos de los modelos disponibles son: árboles de decisión, *random forest* y *ensembles*, XGBoost, regresión polinómica, SVM, reglas de clasificación, k-NN, Naive Bayes o redes neuronales. Cada uno de estos métodos requerirá un preprocesamiento específico que deberá ser debidamente justificado y documentado.

2. Toda la experimentación se realizará mediante **validación cruzada de 5 particiones**. Para sustentar el análisis comparativo se emplearán tablas de errores, matrices de confusión y curvas ROC. Se documentarán métricas de rendimiento como precisión, TPR, TNR, F_1-*score* y AUC, así como medidas de complejidad del modelo (número de hojas, capas ocultas, reglas, nodos, etc.).

3. Se deberán analizar los datos mediante diferentes **gráficas** para comprender su naturaleza y su influencia en el rendimiento de los modelos. Esto supone estudiar aspectos como el balanceo de clases, la distribución y correlación de las variables de entrada, o la presencia de valores nulos.

4. La documentación deberá incluir una **tabla resumen con los resultados** de todos los algoritmos analizados para cada problema. El análisis no podrá reducirse a una simple lectura de las métricas obtenidas, sino que deberá responder a cuestiones como: *¿por qué el algoritmo X funciona mejor que el Y?*, *¿por qué la representación X presenta ventajas respecto a la Y?* o *¿por qué se ha aplicado determinado preprocesamiento?*

5. Para, al menos, uno de los problemas se probarán **configuraciones alternativas de los hiperparámetros** de los algoritmos empleados, justificando los resultados obtenidos. Por ejemplo: *¿es posible evitar o paliar el sobreaprendizaje ajustando los parámetros?* o *¿se pueden obtener modelos más interpretables sin sacrificar excesiva precisión?* Para este análisis se incluirán tablas comparativas entre la configuración por defecto y las distintas variaciones estudiadas. Si el estudio es suficientemente profundo, no será necesario aplicarlo a todos los algoritmos, pudiendo seleccionarse solo algunos de ellos.

6. A la luz de este análisis, se estudiará un **preprocesamiento de datos enfocado a mejorar la predicción** (por ejemplo: eliminación justificada de características, agrupación de categorías, filtrado de instancias erróneas del conjunto de entrenamiento, codificación de variables categóricas, imputación de valores perdidos, balanceo de clases o descomposición de problemas multiclase). Deberán justificarse las acciones tomadas y analizar por qué un determinado procesamiento beneficia a un tipo concreto de algoritmo. Si no se consigue mejorar la predicción, se describirán los procesamientos probados y los resultados obtenidos. Se requiere una tabla resumen que contraponga los resultados antes y después del procesamiento.

7. A partir de todo lo anterior, se extraerán conclusiones sobre los **factores que definen cada clase**. Para ello se podrán analizar los modelos interpretables generados (como árboles de decisión o conjuntos de reglas), así como visualizar las predicciones sobre diferentes casos de entrada (*What-If Analysis*).

1.4. Esquema de la documentación

Para cada problema de clasificación, la documentación entregada deberá ajustarse al siguiente esquema, respetando la numeración y el nombre de cada sección:

1. **Introducción**: se describirá el problema abordado y se ofrecerá un análisis general del *dataset* empleado (dimensiones, tipos de variables, balanceo de clases, presencia de valores perdidos, etc.).

2. **Preprocesamiento de datos**: cuando corresponda, se detallará el tipo de preprocesamiento aplicado (por ejemplo: balanceo de clases, imputación de valores nulos o selección de características). El procesamiento podrá ser común a todos los modelos o específico para determinados algoritmos. Se incluirán capturas de pantalla de KNIME que muestren los flujos de trabajo diseñados.

3. **Resultados obtenidos**: contendrá un subapartado por cada algoritmo estudiado. En cada uno se incluirán capturas de pantalla de KNIME que ilustren el flujo de trabajo configurado, acompañadas de una tabla con las métricas de rendimiento evaluadas.

4. **Análisis de resultados**: incluirá la tabla resumen con todos los algoritmos analizados, así como la interpretación y discusión requeridas en la Tarea 4. Estas tablas resumen deberán maquetarse directamente en el procesador de texto (evitando capturas de pantalla). Se anima a incluir gráficas e ilustraciones (por ejemplo, gráficos de barras o *boxplots*) que respalden el análisis conforme a la Tarea 3.

5. **Configuración de algoritmos**: cuando proceda, se detallará para cada algoritmo la variación de hiperparámetros estudiada, incluyendo una tabla comparativa de resultados y el análisis correspondiente descrito en la Tarea 5.

6. **Interpretación de los datos**: tal como se describe en la Tarea 7, se identificarán los atributos con mayor poder discriminatorio para cada clase. Asimismo, se inspeccionarán los modelos interpretables (por ejemplo, mediante su visualización gráfica) para fundamentar las conclusiones extraídas.

7. **Contenido adicional**: en esta sección se podrá incluir cualquier tarea o análisis complementario no recogido explícitamente en el guion.

8. **Bibliografía**: fuentes, referencias bibliográficas y material técnico consultado para la realización de la práctica.

No se aceptarán otras secciones distintas de éstas. Además, la primera página de la documentación incluirá una **portada** con el **nombre** completo del alumno/a, **grupo** de prácticas y **correo electrónico**. También se incluirá una segunda página con el índice del documento.

1.5. Entrega y evaluación

La calificación máxima de la práctica es de **2,5 puntos**. Se evaluarán la visualización de los datos, la complejidad experimental, la interpretación de los resultados y los contenidos del informe. La fecha límite de entrega será el miércoles **11 de noviembre** hasta las **23:59**. La entrega se realizará a través del espacio de la asignatura en PRADO y contará con los siguientes ficheros:

- **Documentación** en formato `pdf`. El nombre del archivo seguirá el formato: `P1-apellido1-apellido2-nombre.pdf`, sin tildes. Por ejemplo, la alumna "María Teresa del Castillo Gómez" subirá el archivo `P1-delCastillo-Gomez-MariaTeresa.pdf`.

- **Proyecto(s) de KNIME**. Proyectos con extensión `knwf` (resultado de exportarlos desde KNIME) con los que se ha resuelto cada problema.

En ningún caso se aceptarán entregas a través de enlaces como Dropbox, Google Drive, WeTransfer o similares.